


Raport – SVM margines and kernels
Podstawy nauczania maszynowego
Wyk. Mateusz Woś


Do wykonania zadania wygenerowałem obraz przy pomocy Paint'a tak jak w zamieszczonym załączniku. Poniżej dane pierwotne i po zaczytaniu. Tak jak w poprzednich zadaniach dane wyeksportowałem do pliku csv(w postaci współrzędna x, y, numer koloru, nazwa koloru), aby później łatwo z nich korzystać.




Za współczynnik **C** dla poniższych obliczeń obrałem wartości :

[0.00001, 0.0001, 0.001, 0.01, 0.1 , 1, 10, 100]


Standardowe SVM.






W klasycznym SVM można zauważyć, że wzrost parametru C powoduje zmniejszenie się wielkości marginesu. Dopasowanie jest coraz bardziej dokładne ze wzrostem C, idziemy w stronę overfittingu.

SVM Z kernelem wielomianowym trzeciego stopnia







Tutaj podobnie jak w klasycznym SVM. Wraz ze wzrostem C maleje margines. Dodatkowo można zauważyć iż przy większych parametrach C strasznie słabnie dokładność klasyfikacji. (Overfitting)

SVM z kernelem RBF


Oprocz modyfikacji parametrem C. Zmienialem wartość parametru gamma. Odpalilem klasyfikację dla 4 różnych wartości gamma: [0.0001, 0.1, 1, 10]


- **Gamma = 0.0001**







- **Gamma = 0.1**







- **Gamma = 1**



- **Gamma = 10**



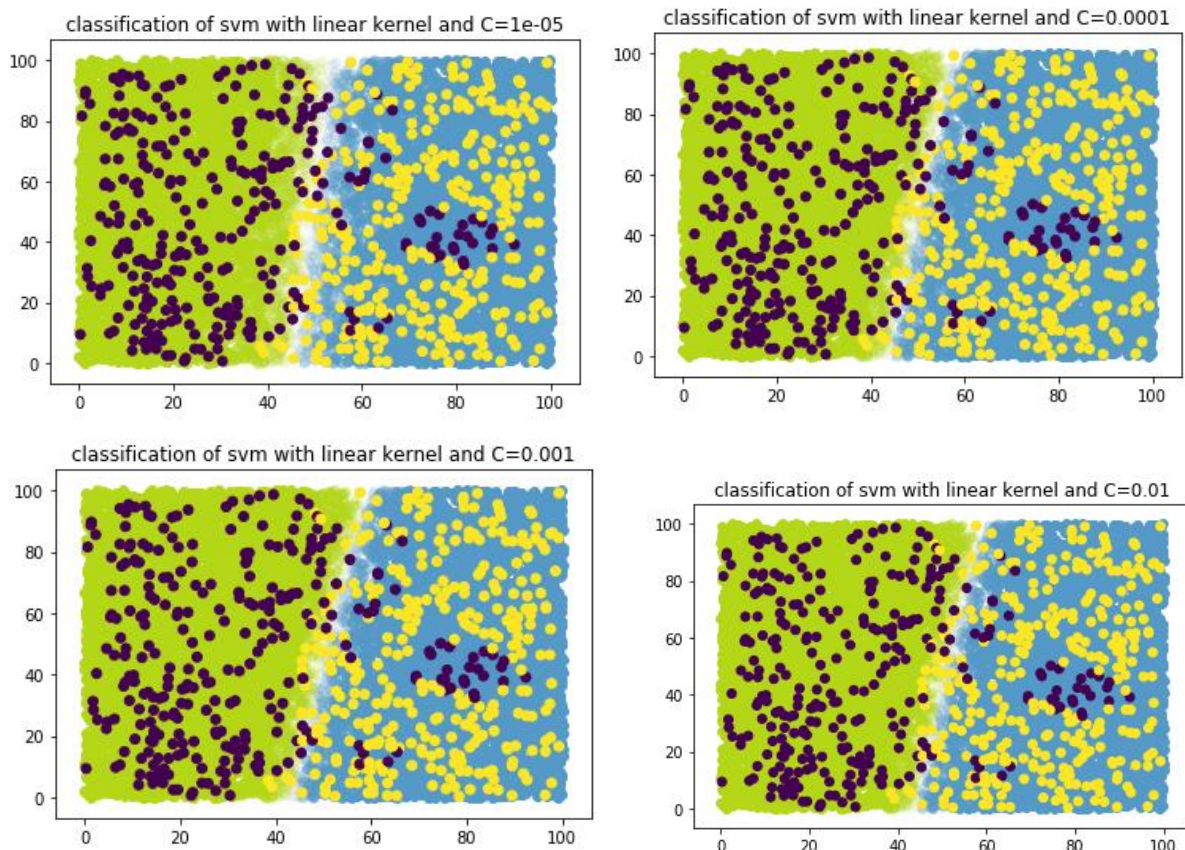
SVM z kernelem RBF idealnie klasyfikuje dane. Można to zauważyć na początkowych wykresach z małymi wartościami C , gdzie test acc i train acc praktycznie się pokrywają. RBF overfittuje dla $C \geq 1$.

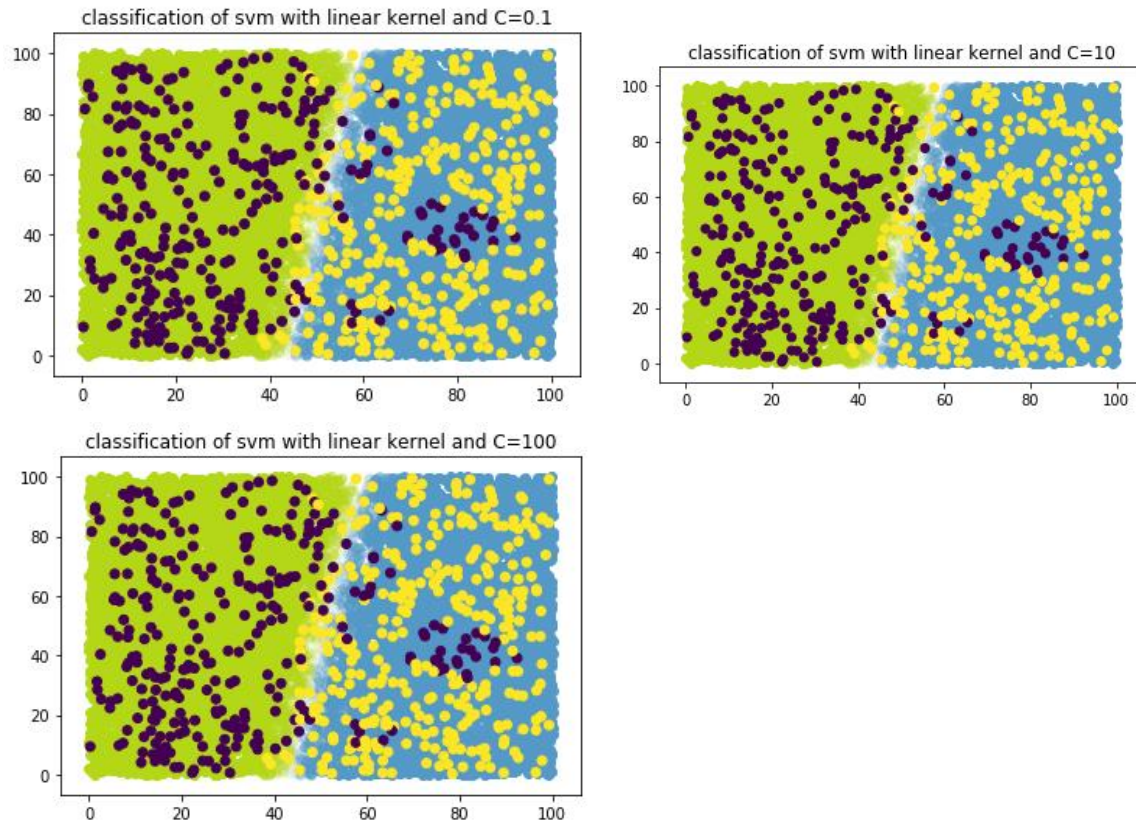
Wizualizacja efektów działania klasyfikacji:

Miałem trudności z odpowiednim kolorowaniem, więc punkty wejściowe teraz odpowiednio są reprezentowane przez kolory: czerwony -> fioletowy, niebieski -> żółty.

Obszary: obszar zielony pokazuje obszar zaklasyfikowany jako klasa 1 (czerwone punkty), natomiast niebieski jako klasa 2 (niebieskie punkty)


- **Klasyczny SVM**






Wszystko wygląda bardzo podobnie


- SVM z wielomianowym kernelem.




classification of svm with poly kernel (3rd degree polynomial) and $C=0.0001$




classification of svm with poly kernel (3rd degree polynomial) and $C=0.001$




classification of svm with poly kernel (3rd degree polynomial) and $C=0.01$




classification of svm with poly kernel (3rd degree polynomial) and $C=0.1$




classification of svm with poly kernel (3rd degree polynomial) and $C=1$



classification of svm with poly kernel (3rd degree polynomial) and $C=10$



classification of svm with poly kernel (3rd degree polynomial) and $C=100$




Widać jak ze wzrostem C model zaczyna overfitować, przestaje generalizować.


SVM z kernelem RBF:

- $C = 0.0001$


classification of svm with rbf kernel, $\gamma=0.001$ and $C=0.0001$



classification of svm with rbf kernel, gamma=0.01 and C=0.0001




classification of svm with rbf kernel, gamma=0.1 and C=0.0001




- **C = 1**


classification of svm with rbf kernel, gamma=0.001 and C=1



classification of svm with rbf kernel, gamma=0.01 and C=1




classification of svm with rbf kernel, gamma=0.1 and C=1




- **Dla $C = 50$**


classification of svm with rbf kernel, gamma=0.001 and C=50



classification of svm with rbf kernel, gamma=0.01 and C=50



classification of svm with rbf kernel, gamma=0.1 and C=50



Mała wartość C spowodowała, iż wszystko zostało zaklasyfikowane jako klasa 2. RBF jako jedyny dobrze radzi sobie z kolistym zbiorem punktów czerwonych w obszarze punktów niebieskich. Wraz ze wzrostem parametru γ obszary stają się coraz bardziej „wyostnione”

Wnioski:

- Kernel RBF idealnie nadaje się do klasyfikacji zbiorów gdzie klasy zawierają się w sobie
- Duże wartości parametru C mogą doprowadzić do zjawiska overfitingu. Dane treningowe zostaną świetnie dopasowane, lecz dokładność na danych treningowych może być tragiczna.
- Tradycyjny SVM i z kernelem wielomianowym nie radziły sobie zbyt dobrze z szumami w zbiorze (np. punkty klasy 1 w klasie 2). Tradycyjny SVM nadaje się tylko do klasyfikacji prostych, niezaszumionych danych.
- SVM daje ogółem bardzo dobre wyniki w problemie klasyfikacji.